

Báo cáo kỹ thuật — Bài báo cáo 1: Tiền Xử lý

1. Yêu cầu của Bài 1 và dữ liệu được chọn

Theo yêu cầu của giảng viên, nhóm phải chọn ba bộ dữ liệu. Mỗi bộ cần có ít nhất 10.000 bản ghi và 30 thuộc tính, còn vấn đề chất lượng để khảo sát, có nguồn hợp pháp và dùng được cho ít nhất hai kỹ thuật khai phá. Ba bộ kết hợp phải phủ đủ phân lớp, luật kết hợp và gom cụm.

Bộ dữ liệu	Quy mô dùng để khảo sát	Phân lớp	Luật kết hợp	Gom cụm
Olist Brazilian E-Commerce	118.310 dòng × 35 cột	Chọn	Không chọn	Chọn
Inside Airbnb - New York City	30.259 dòng × 90 cột	Không chọn	Chọn	Chọn
US Accidents	80.000 dòng × 46 cột	Chọn	Chọn	Không chọn

Olist được chọn cho phân lớp vì có thể tạo nhãn đơn giao trễ, và cho gom cụm vì có thể xây dựng RFM theo khách hàng. Airbnb được chọn cho luật kết hợp vì mỗi listing có một giỏ tiện nghi tự nhiên, và cho gom cụm vì các listing có thể chia thành nhóm theo giá, sức chứa và đánh giá. US Accidents được chọn cho phân lớp Severity và luật kết hợp giữa thời gian, thời tiết, hạ tầng và mức độ tai nạn.

Quy mô trong bảng là quy mô tại bước khảo sát. Các tệp dùng cho mô hình có thể ít cột hơn vì nhóm đã loại mã định danh, văn bản dài, cột hằng hoặc thuộc tính không phù hợp. Việc giảm số cột sau khảo sát không làm mất điều kiện 30 thuộc tính của dữ liệu gốc.

Nhóm vẫn cần xác nhận với giảng viên rằng ba bộ này chưa được dùng làm ví dụ trên lớp. Notebook và dữ liệu không thể tự chứng minh điều đó.

2. Olist Brazilian E-Commerce

2.1. Nguồn gốc và giấy phép

Tên bộ dữ liệu: Brazilian E-Commerce Public Dataset by Olist. Ngày tải dữ liệu: 21/08/2026. Đơn vị công bố: Olist, đăng tải trên Kaggle.

Đường dẫn chính thức: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>. Giấy phép: CC BY-NC-SA 4.0. Khi sử dụng phải ghi nguồn, chỉ dùng trong phạm vi phi thương mại và giữ điều kiện chia sẻ tương tự. Bộ dữ liệu không dùng tên thật của khách hàng; các mã khách hàng đã được thay bằng mã định danh.

Bộ Olist gồm chín tệp CSV về đơn hàng, sản phẩm, khách hàng, người bán, thanh toán, đánh giá, vị trí và bản dịch ngành hàng. Notebook đọc cả chín tệp. Bảng khảo sát không ghép bảng geolocation vì bảng này có nhiều dòng cho một mã bưu chính và có thể làm số dòng tăng mạnh nếu nối trực tiếp.

2.2. Cách gộp bảng và đơn vị quan sát


Bảng khảo sát bắt đầu từ order_items. Sau đó lần lượt nối orders, customers, products, sellers, bản dịch ngành hàng, payments và reviews. Năm bảng đầu có quan hệ nhiều-một với item và đã được kiểm tra khóa. Payments và reviews có thể có nhiều dòng trong cùng một đơn, nên sau khi nối một item có thể xuất hiện nhiều lần.

Kiểm tra	Kết quả	Cách hiểu
Orders gốc	99.441 đơn	Tổng số đơn trong bảng orders
Order items	112.650 dòng	Một đơn có thể có nhiều sản phẩm
Sau gộp	118.310 × 35	Bảng khảo sát liên bảng, không phải 118.310 đơn
Đơn có nhiều payment	2.961	Phải cộng tiền theo order trước khi phân tích
Đơn có nhiều review	547	Không coi dòng tăng thêm là đơn mới
Trùng toàn dòng	419	Loại xong còn 117.891 × 35

Không được cộng trực tiếp payment_value trên bảng đã gộp, vì tiền có thể bị lặp theo số item và số review. Notebook tạo dữ liệu phân lớp từ orders và order_items đã tổng hợp theo order. Dữ liệu RFM được tạo từ orders, customers và tổng thanh toán của từng order. Cách làm này giữ đúng đơn vị phân tích.

2.3. Điều tra tri thức lĩnh vực — Olist

Olist là dữ liệu thương mại điện tử của Brazil, mô tả toàn bộ vòng đời một đơn hàng: khách đặt hàng, người bán xử lý, đơn vị vận chuyển giao hàng, và khách để lại đánh giá sau khi nhận. Một đơn hàng có thể gồm nhiều sản phẩm, mỗi sản phẩm có thể do một người bán khác nhau cung cấp và thuộc một danh mục ngành hàng riêng; các bảng đơn hàng, sản phẩm, khách hàng, người bán, thanh toán và đánh giá liên kết với nhau qua các mã khóa. Vì dữ liệu mô tả một quy trình vận hành thật (không phải bảng số ngẫu nhiên), các thuộc tính có quan hệ nghiệp vụ rõ ràng với nhau — đây là cơ sở để lập luận khả năng khai phá bên dưới.



Hình 1. Phân phối review_score — khảo sát trực quan lúc chọn biến mục tiêu

Vì dữ liệu có đủ mốc thời gian của một đơn hàng — ngày đặt, ngày giao dự kiến, ngày giao thực tế — nhóm có thể dẫn xuất `delivery_delay_days` (chênh lệch giữa ngày giao thực tế và ngày giao dự kiến) và từ đó `is_late`. Đây là nhãn có ý nghĩa nghiệp vụ thật: dự đoán được đơn có nguy cơ giao trễ giúp chủ sàn can thiệp sớm. Đây là căn cứ để chọn Olist cho Bài 2 (Phân lớp).

Ở cấp khách hàng, có thể tổng hợp số lần mua, tổng giá trị đã chi và thời gian từ lần mua gần nhất để dựng ba đặc trưng RFM (`recency_days`, `frequency`, `monetary`). Nhóm khách hàng tương đồng theo ba trục này là một bài toán gom cụm có ý nghĩa nghiệp vụ kinh điển (phân khúc khách hàng). Đây là căn cứ để chọn Olist cho Bài 4 (Gom cụm).

Với luật kết hợp, về lý thuyết mỗi đơn hàng có thể xem là một "giỏ hàng" gồm các sản phẩm/ngành hàng cùng mua. Tuy nhiên khảo sát `basket_size` trên dữ liệu thật cho thấy phần lớn đơn chỉ có một sản phẩm hoặc một ngành hàng, nên tập item sinh ra sẽ quá thừa để tìm luật có ý nghĩa. Đây là lý do — dựa trên tri thức lĩnh vực và số liệu khảo sát, không phải lựa chọn tùy ý — nhóm không đưa Olist vào Bài 3 (Luật kết hợp).

2.4. Khả năng khai phá

Phân lớp: mục tiêu là dự đoán is_late. Một đơn được gán trễ khi delivery_delay_days lớn hơn 0. Những thông tin xảy ra sau lúc đặt hàng, như ngày giao thực tế, chỉ dùng để tạo nhãn và không được đưa vào đặc trưng dự báo.

Gom cụm: mỗi dòng là một khách hàng duy nhất. Ba đặc trưng RFM gồm recency_days - số ngày từ lần mua gần nhất đến mốc quan sát; frequency - số đơn duy nhất; monetary - tổng số tiền thanh toán. customer_unique_id chỉ dùng để nhận diện và mô tả cụm, không dùng tính khoảng cách.

Luật kết hợp không được chọn cho Olist vì phần lớn đơn có ít sản phẩm hoặc ít ngành hàng khác nhau. Tạo giỏ giả bằng cách gộp nhiều đơn của cùng khách hàng sẽ làm thay đổi ý nghĩa giao dịch nên nhóm không làm như vậy.


2.5. Giá trị thiếu

Thuộc tính	Tỷ lệ thiếu	Quyết định
order_delivered_customer_date	2,19%	Không điền ngày giả; đơn không đủ điều kiện tạo nhãn
product_photos_qty / mô tả / tên	khoảng 1,44%	Giữ NA hoặc xử lý trong pipeline theo kỹ thuật
order_delivered_carrier_date	1,06%	Không điền vì có thể đơn chưa đến bước giao vận
review_score	0,83%	Không điền trung bình vì sẽ tạo đánh giá không có thật
Kích thước, trọng lượng sản phẩm	khoảng 0,02%	Điền hoặc loại trong pipeline tùy thuật toán

Thiếu ngày giao có thể liên quan trạng thái đơn chưa hoàn thành; thiếu review có thể liên quan việc khách không đánh giá. Vì vậy đây có thể là thiếu có hệ thống. Báo cáo chỉ nêu giả thuyết nghiệp vụ, không khẳng định đã chứng minh MCAR, MAR hoặc MNAR.

2.6. Ngoại lai và kiểm tra logic


Thuộc tính	Số điểm ngoài IQR	Tỷ lệ
price	8867	7,49%
freight_value	12740	10,77%
payment_value	9549	8,07%
product_weight_g	16696	14,11%



Hình 2. Boxplot các thuộc tính số chính — Olist (price, freight_value, payment_value, product_weight_g)

IQR chỉ đánh dấu giá trị khác biệt, không chứng minh chúng sai. Giá sản phẩm, phí vận chuyển và trọng lượng lớn vẫn có thể hợp lệ. Notebook không xóa hàng loạt các điểm này. Với gom cụm, nên dùng log1p cho biến lệch phải và chuẩn hóa trong Bài 4. Không phát hiện giá âm; cũng không có trường hợp ngày giao trước ngày đặt trong kiểm tra đã lưu.

2.6. Dữ liệu đầu ra Olist



Lớp trễ chỉ chiếm 6,77%, vì vậy Bài 2 phải dùng *precision*, *recall*, *F1* và ma trận nhầm lẫn, không chỉ dùng *accuracy*.

Hình 3. Phân bố nhãn giao trễ Olist

Tập phân lớp có 96.476 dòng $\times$ 11 cột. Trong đó có tám đặc trưng phục vụ dự báo: tháng, thứ và giờ đặt hàng; số item; số sản phẩm; số người bán; tổng giá sản phẩm; tổng phí vận chuyển. `order_id` là khóa đối soát, `order_purchase_timestamp` dùng chia tập theo thời gian và `is_late` là nhãn.

Cần hiểu đúng quy tắc nhãn: notebook dùng `.dt.days > 0`, tức số ngày nguyên lớn hơn 0. Kiểm tra trực tiếp cho thấy 7.827 đơn có timestamp giao sau timestamp dự kiến, nhưng 1.292 đơn chênh chưa đủ 24 giờ không vào lớp trễ hiện tại. Báo cáo giữ nguyên 6.535 nhãn trễ để khớp notebook. Nếu đổi quy ước, nhóm phải tạo lại nhãn và chạy lại Bài 2.

Tập gom cụm có 96.096 khách hàng $\times$ 4 cột. Recency trung vị 268 ngày; frequency trung vị 1; monetary trung vị 108 và lớn nhất 13.664,08. Frequency có Q1, trung vị và Q3 đều bằng 1 nên khả năng phân tách theo tần suất còn hạn chế. Monetary lệch mạnh nên cần biến đổi và co giãn trước khi gom cụm.

RFM hiện được tính trên toàn bộ lịch sử đơn hàng. Nếu dùng RFM để dự đoán tại một thời điểm quá khứ, phải chỉ dùng giao dịch xảy ra trước thời điểm đó để tránh nhìn thấy tương lai.

2.7. Thêm / Xóa / Biến đổi thuộc tính (tổng hợp)

Xóa: mã định danh gây trùng dòng sau khi gộp bảng — `order_id` có thể lặp do `payments/reviews` nhiều dòng trên một đơn, phải tổng hợp theo order trước khi dùng, không xóa thẳng vì sẽ mất thông tin.

các mốc thời gian xảy ra sau lúc đặt hàng (ngày giao thực tế, ngày giao vận) — không đưa vào đặc trưng dự báo `is_late` vì đây là thông tin rò rỉ nhãn, chỉ dùng để tạo nhãn.

Thêm: `delivery_delay_days` và `is_late` — dẫn xuất từ hiệu (ngày giao thực tế – ngày giao dự kiến); là nhãn cho Bài 2.

`recency_days`, `frequency`, `monetary` (RFM) — dẫn xuất từ `orders`, `customers` và tổng thanh toán theo order; là đặc trưng cho Bài 4.

Biến đổi: gộp nhiều dòng `payments/reviews` về một dòng theo order trước khi tổng hợp tiền hoặc điểm đánh giá.

3. Inside Airbnb - New York City

3.1. Nguồn gốc và đơn vị quan sát

Nguồn chính thức: Inside Airbnb - Get the Data, mục New York City, tệp Detailed Listings. Ngày tải dữ liệu: 21/08/2026. Đường dẫn: <https://insideairbnb.com/get-the-data/>. Đơn vị công bố là Inside Airbnb, không phải Kaggle và không phải dữ liệu nội bộ do Airbnb giao trực tiếp. Trang nguồn ghi giấy phép Creative Commons Attribution 4.0 International - CC BY 4.0. Khi sử dụng phải ghi nguồn Inside Airbnb.

Mỗi dòng mô tả một listing tại thời điểm thu thập, không phải một lượt đặt phòng. Dữ liệu có 30.259 dòng × 90 cột. Giá là giá niêm yết tại thời điểm thu thập. `availability_365` là số ngày hiển thị có thể đặt; giá trị thấp không tự chứng minh phòng đã được đặt vì chủ nhà có thể khóa lịch.

3.2. Điều tra tri thức lĩnh vực — Airbnb NYC

Inside Airbnb là dữ liệu snapshot về thị trường cho thuê lưu trú ngắn hạn tại New York City. Mỗi dòng mô tả một listing tại thời điểm thu thập, gồm thông tin về host, vị trí, loại phòng, sức chứa, giá niêm yết, điểm đánh giá, mức độ hoạt động (`availability`) và danh sách tiện nghi. Đây là dữ liệu mô tả hành vi cung cấp dịch vụ lưu trú thật, các thuộc tính có quan hệ nghiệp vụ với nhau — giá niêm yết có thể liên hệ với vị trí, loại phòng, sức chứa, số phòng ngủ, số lượng tiện nghi và uy tín của host (`host_is_superhost`, `review_scores_rating`, số lượt review).

Thuộc tính amenities liệt kê nhiều tiện nghi cùng lúc trên một listing (Wifi, bếp, máy giặt, hồ bơi...). Mỗi listing vì vậy có thể biểu diễn tự nhiên như một giao dịch (transaction) gồm nhiều item, đúng cấu trúc "giỏ" mà luật kết hợp cần — không phải rời rạc hóa gượng ép một thuộc tính số. Đây là căn cứ chọn Airbnb cho Bài 3 (Luật kết hợp).

Đồng thời, mỗi listing cũng có thể biểu diễn bằng một vector đặc trưng số — giá, sức chứa, số phòng, số đánh giá, availability, số tiện nghi, hoạt động host — để gom thành các phân khúc lưu trú tương đồng về mặt dữ liệu (ví dụ: listing giá cao sức chứa lớn nhiều tiện nghi so với listing giá thấp cơ bản). Đây là căn cứ chọn Airbnb cho Bài 4 (Gom cụm).

3.3. Hai kỹ thuật được chọn

Luật kết hợp: mỗi listing là một giao dịch; mỗi tiện nghi trong amenities là một item. Cách định nghĩa này tự nhiên vì nhiều tiện nghi cùng xuất hiện trong một chỗ ở. Nhóm có thể tìm các bộ tiện nghi thường đi cùng nhau bằng support, confidence và lift.

Gom cụm: mỗi listing được mô tả bằng giá, sức chứa, số phòng, số đánh giá, điểm đánh giá, khả dụng, số listing của host và số tiện nghi. Các nhóm tạo ra có thể cho biết những kiểu listing tương đồng về mặt dữ liệu.

Notebook còn tạo một tệp phân lớp Superhost để tham khảo, nhưng phân lớp không nằm trong ma trận chính thức. Nếu dùng về sau cần kiểm tra rò rỉ, vì điểm đánh giá và hoạt động của host có thể liên quan trực tiếp tiêu chí Superhost.

3.4. Bảo vệ thông tin và loại thuộc tính

Notebook loại host_name, host_url, host_thumbnail_url, host_picture_url, host_about, listing_url và picture_url. Mười một cột thiếu 100% cũng bị loại. Văn bản dài như name và description không được dùng trong hai ma trận kỹ thuật vì nhóm không thực hiện NLP. Mã id và host_id chỉ dùng kiểm tra, không dùng tính khoảng cách.


Việc bỏ bảy cột chưa có nghĩa bảng trung gian đã ẩn danh hoàn toàn. Tên listing, mô tả, tọa độ hoặc URL khác vẫn có thể giúp nhận diện lại. Vì vậy chỉ nên chia sẻ bảng đầu ra đã tối giản hoặc tiếp tục rà soát các trường liên kết được với host.

3.5. Thiếu dữ liệu, ngoại lai và biến đổi


Vấn đề	Số liệu chính	Cách xử lý
license thiếu	82,53%	Giữ để mô tả chất lượng; không dùng cho hai kỹ thuật
bedrooms thiếu	36,31%	Gom cụm: điền trung vị theo room_type
bathrooms thiếu	33,42%	Gom cụm: điền trung vị theo room_type
beds thiếu	31,13%	Gom cụm: điền trung vị theo room_type
price thiếu	28,90%	Chuyển chuỗi sang số rồi điền cho tập gom cụm
điểm review thiếu	khoảng 28,3%	Điền theo room_type; phải ghi nhận nguy cơ giảm phương sai

Mười một cột thiếu toàn bộ có thể do phiên bản schema hoặc cách thu thập, không nên gọi là thiếu ngẫu nhiên. Điểm review thường thiếu khi listing chưa có đánh giá. Giá trị trung vị được điền giúp thuật toán chạy được nhưng không trở thành quan sát thật; cần kiểm tra độ nhạy của cụm với cách điền.

Thuộc tính	Số ngoại IQR	Tỷ lệ	Nhận xét
price_num	1608	7,47%	Giá cao có thể hợp lệ
minimum_nights	6455	21,33%	IQR bằng 0; không xóa chỉ vì bị gán cờ
accommodates	1072	3,54%	Kiểm tra cùng room_type
bedrooms	707	3,67%	Studio có thể có 0 phòng ngủ
beds	1600	7,68%	Kiểm tra cùng sức chứa



Hình 4. Phân phối giá niêm yết price_num (đã cắt phân vị 99% để dễ nhìn) — Airbnb



Hình 5. Boxplot các thuộc tính số chính — Airbnb (price_num, minimum_nights, accommodates, bedrooms, beds)

Price được bỏ ký hiệu tiền và dấu phân tách rồi chuyển sang số. price_per_person bằng price_num chia accommodates. amenities được chuyển thành danh sách; amenity_count là số tiện nghi. Có 392 listing có accommodates nhỏ hơn bedrooms. Đây chỉ là cảnh báo mềm vì chủ nhà có thể giới hạn số khách hoặc cho thuê một phần nhà; notebook không xóa các dòng này.

Tập luật kết hợp bỏ 41 giỏ rỗng, còn 30.218 giao dịch × 182 item. Các tiện nghi có support dưới 0,5% bị loại. Số item trung bình là 27,80; có 30.197 giỏ, tương đương 99,93%, chứa ít nhất hai item. Không xóa các giỏ giống nhau vì các listing khác nhau có thể có cùng bộ tiện nghi.

Tập gom cụm có 30.259 dòng × 16 cột và không còn thiếu. Dữ liệu mới được điền thiếu, chưa được scaling. Bài 4 cần StandardScaler hoặc RobustScaler trước các thuật toán dựa trên khoảng cách. price_num và price_per_person có thể mang thông tin gần nhau, vì vậy phải kiểm tra tương quan để tránh tính giá hai lần.

3.6. Thêm / Xóa / Biến đổi thuộc tính (tổng hợp)

Xóa: `host_name`, `host_url`, `host_thumbnail_url`, `host_picture_url`, `host_about`, `listing_url`, `picture_url` — thông tin định danh/URL cá nhân, không cần cho hai kỹ thuật và có nguy cơ lộ danh tính.

11 cột thiếu 100% dữ liệu (không mang thông tin); `name`, `description` — văn bản dài, nhóm không thực hiện NLP nên không đưa vào ma trận kỹ thuật.

Thêm: `price_per_person` = `price_num` / `accommodates` — chuẩn hóa giá theo sức chứa để so sánh công bằng hơn giữa các loại phòng. `amenity_count` — số lượng tiện nghi, dẫn xuất từ độ dài danh sách `amenities`.

Biến đổi: `price`: chuyển từ chuỗi có ký hiệu tiền (\$, dấu phẩy) sang số. `amenities`: chuyển từ chuỗi sang danh sách rồi nhị phân hóa thành 182 cột item (mỗi tiện nghi 1 cột) cho tập luật kết hợp. `bedrooms`, `bathrooms`, `beds`, `price`: điền thiếu bằng trung vị theo `room_type` (không dùng trung vị toàn cục vì các loại phòng có quy mô khác nhau rõ rệt).

Chuẩn hóa/scaling (`StandardScaler` hoặc `RobustScaler`) và cân nhắc log-transform cho `price_num`, `host_listings_count` trước khi gom cụm.

4. US Accidents

4.1. Nguồn gốc và cách lấy mẫu

Tên bộ dữ liệu: US Accidents (2016-2023). Ngày tải dữ liệu: 21/08/2026. Tác giả/công bố: Sobhan Moosavi và cộng sự, đăng tải trên Kaggle.

Đường dẫn: <https://www.kaggle.com/datasets/sobhanmoosavi/us-accidents>. Giấy phép: CC BY-NC-SA 4.0. Đây là dữ liệu sự kiện tai nạn được tổng hợp từ các nguồn giao thông. `Severity` mô tả mức độ ảnh hưởng của sự kiện theo bộ dữ liệu; không được tự hiểu là số người bị thương hoặc tử vong.

Notebook đọc tệp theo từng chunk 200.000 dòng, chỉ giữ California và Texas. Có 2.324.270 dòng CA/TX trước lấy mẫu. Mỗi dòng được gán một khóa ngẫu nhiên bằng `default_rng(42)`; chương trình giữ 80.000 khóa nhỏ nhất. Kết quả gồm 59.903 dòng CA và 20.097 dòng TX. Đây không phải lấy 80.000 dòng đầu và cũng không phải chia đều hai bang.

Mẫu CA/TX không đại diện toàn nước Mỹ. Dữ liệu chỉ chứa tai nạn đã được ghi nhận, không có số giờ lái xe hoặc lưu lượng ở những thời điểm không xảy ra tai nạn. Vì vậy tần suất đồng xuất hiện không phải xác suất gây tai nạn.

4.2. Điều tra tri thức lĩnh vực — US Accidents


US Accidents mô tả các vụ tai nạn giao thông tại Hoa Kỳ giai đoạn 2016–2023, gồm thời gian, vị trí, mức độ nghiêm trọng, điều kiện thời tiết và các đặc điểm hạ tầng giao thông tại nơi xảy ra tai nạn (giao lộ, đèn tín hiệu, đường sắt, biển báo...). Severity là biến mục tiêu tự nhiên cho bài toán phân lớp vì nó biểu diễn trực tiếp mức độ ảnh hưởng của vụ tai nạn theo cách gán nhãn của bộ dữ liệu; các thuộc tính thời tiết (nhiệt độ, độ ẩm, tầm nhìn, tốc độ gió, lượng mưa) và thời gian (giờ, ngày trong tuần) có quan hệ nghiệp vụ hợp lý với mức độ nghiêm trọng, nên có thể dùng làm đặc trưng dự báo.

Các cờ hạ tầng (Crossing, Junction, Traffic_Signal, Railway, Stop, Amenity...) có dạng nhị phân sẵn, về nguyên tắc là item tự nhiên cho luật kết hợp. Tuy nhiên khảo sát tần suất cho thấy phần lớn các cờ này khá hiếm (đa số dưới 10%), nên nếu chỉ dùng riêng chúng thì phần lớn giao dịch sẽ có 0–1 item — không đủ dày để sinh luật có ý nghĩa. Vì vậy nhóm kết hợp thêm các thuộc tính đã rời rạc hóa (khung giờ, ngày thường/cuối tuần, nhóm nhiệt độ, nhóm thời tiết, ngày/đêm) và nhóm mức độ nghiêm trọng làm item bổ sung, để mỗi giao dịch có đủ item cho Apriori/FP-Growth khai phá. Đây là căn cứ chọn US Accidents cho cả Bài 2 (Phân lớp) và Bài 3 (Luật kết hợp).

Nhóm không chọn US Accidents cho gom cụm: các đặc trưng thời tiết/hạ tầng ở đây mô tả sự kiện tai nạn tại một thời điểm, không phải một thực thể ổn định theo thời gian (như khách hàng hay listing), nên phân cụm sẽ khó diễn giải thành các nhóm có ý nghĩa nghiệp vụ ổn định.

4.3. Hai kỹ thuật được chọn

Phân lớp: dự đoán Severity gồm bốn lớp 1, 2, 3 và 4 từ thời tiết, thời gian, khoảng cách ảnh hưởng và cờ hạ tầng. Nếu mục tiêu là dự báo ngay khi tai nạn bắt đầu, cần kiểm tra Distance(mi) có sẵn ở thời điểm dự báo hay chỉ được xác định sau đó.



Hình 6. Phân bố Severity trong mẫu 80.000 dòng

Luật kết hợp: mỗi tai nạn là một giao dịch. Item gồm cờ hạ tầng, khung giờ, ngày thường/cuối tuần, nhóm nhiệt độ, nhóm thời tiết, ngày/đêm và mức độ nhẹ/nặng. Nếu chỉ dùng cờ hạ tầng thì giỏ quá thưa, nên nhóm bổ sung các thuộc tính đã rời rạc hóa.

4.3. Thiếu dữ liệu và vấn đề thời gian

Thuộc tính	Tỷ lệ thiếu	Xử lý / lưu ý
End_Lat, End_Lng	42,99%	Loại vì thiếu nhiều và không cần cho hai kỹ thuật
Precipitation(in)	34,12%	Tạo cờ thiếu; phân lớp điền trung vị State/tháng
Wind_Chill(F)	31,65%	Không dùng trong tập phân lớp chính
Start_Time / Hour_of_Day	9,04%	Cần parse lại từ chuỗi gốc
Wind_Speed(mph)	8,76%	Điền theo State/tháng cho CSV phân lớp
Humidity(%)	2,42%	Điền theo State/tháng cho CSV phân lớp

Tập phân lớp hiện không còn thiếu vì notebook đã điền trung vị theo State và tháng, sau đó dùng trung vị toàn cục nếu nhóm vẫn thiếu. Tuy nhiên phép điền được fit trước khi chia train/test nên có rò rỉ thông tin thống kê. Trong Bài 2, cách đúng là fit imputer chỉ trên train trong từng fold.

Có 7.236 giá trị Hour_of_Day thiếu. Nguyên nhân kỹ thuật có thể là Start_Time đã bị ép thành NaT bằng cách parse chưa phù hợp trước khi code dùng format='mixed'. Khi chuỗi gốc đã thành NaT thì


parse lần nữa không thể khôi phục. Nhóm cần đọc lại Start_Time từ tệp gốc rồi tạo Hour_of_Day, Day_of_Week và Is_Weekend.

Trong luật kết hợp, thời gian không đọc được được giữ thành item Unknown. Trong phân lớp, Hour_of_Day được điền trung vị. Unknown là trạng thái chất lượng dữ liệu, không phải một thời điểm thật; không dùng nó để đưa ra kết luận nghiệp vụ.

4.4. Ngoại lai và rời rạc hóa

Thuộc tính	Số ngoài IQR	Tỷ lệ	Quyết định
Temperature(F)	245	0,31%	Giữ nếu nằm trong miền hợp lý
Visibility(mi)	16719	21,35%	IQR bằng 0; giữ tầm nhìn thấp/cao có ý nghĩa
Wind_Speed(mph)	1227	1,68%	Kiểm tra miền, không xóa tự động
Distance(mi)	10375	12,97%	Đoạn ảnh hưởng dài có thể hợp lệ

Không phát hiện độ ẩm ngoài 0-100%, giá trị âm ở visibility, wind speed, precipitation hoặc distance, và không có nhiệt độ trên 130°F trong phép kiểm tra đã lưu. IQR là công cụ phát hiện, không phải quy tắc xóa.



Hình 7. Boxplot các thuộc tính số chính — US Accidents (Temperature, Visibility, Wind_Speed, Distance)

Nhiệt độ được chia thành rất lạnh $(-100,32]$, lạnh $(32,60]$, vừa $(60,80]$ và nóng $(80,200]$ °F. Khung giờ gồm sáng 5-10, trưa/chiều 11-16, tối 17-20 và đêm 21-4. Nhóm thời tiết được tạo bằng từ khóa. Cần kiểm tra thứ tự điều kiện vì một chuỗi vừa có thunder vừa có rain có thể bị xếp vào mưa trước khi đến nhóm bão.

4.5. Dữ liệu đầu ra US Accidents

Tập phân lớp có 80.000 dòng $\times$ 23 cột, gồm 22 đặc trưng và nhãn Severity. Lớp 1 có 520 dòng; lớp 2 có 65.334; lớp 3 có 13.439; lớp 4 có 707. Bài 2 phải báo cáo macro-F1, recall từng lớp, precision và ma trận nhầm lẫn. Nếu chỉ báo accuracy thì mô hình luôn đoán lớp 2 cũng có vẻ tốt.

Tập luật kết hợp có 80.000 giao dịch $\times$ 32 item. Sau khi lọc item có support dưới 0,1%, mỗi giỏ có từ 5 đến 11 item, trung bình 6,365; tất cả giao dịch có ít nhất hai item. Severity được phép dùng như item để tìm luật trong Bài 3, nhưng không được dùng làm đặc trưng khi mục tiêu của Bài 2 cũng là Severity.

Các luật giữa giờ và Day/Night hoặc giữa Severity và nhóm mức độ có thể là luật hiển nhiên do một biến được suy ra từ biến kia. Bài 3 phải loại các luật như vậy, đồng thời không diễn giải support trong tập tai nạn như nguy cơ tai nạn của toàn bộ người tham gia giao thông.

Country và Turning_Loop bị loại vì là cột hằng trong mẫu. End_Lat và End_Lng bị loại vì thiếu nhiều. ID, Description và các trường địa chỉ không đưa vào ma trận phân lớp chính. Cờ hạ tầng đã là Boolean nên không cần one-hot lần nữa.

4.6. Thêm / Xóa / Biến đổi thuộc tính (tổng hợp)

Xóa: Country, Turning_Loop — cột hằng trong mẫu, không mang thông tin phân biệt. End_Lat, End_Lng — thiếu 42,99%, không cần cho hai kỹ thuật đã chọn. ID, Description và các trường địa chỉ chi tiết (Street, City, County, State, Zipcode, Airport_Code) — định danh/văn bản tự do, không đưa vào ma trận kỹ thuật chính; State được giữ lại riêng để điền thiếu theo nhóm.

Thêm: Hour_of_Day, Day_of_Week, Is_Weekend — dẫn xuất từ Start_Time, cần cho cả rời rạc hóa (Bài 3) và đặc trưng thời gian (Bài 2). Nhóm nhiệt độ, khung giờ, nhóm thời tiết, ngày/đêm, nhóm mức độ Nhẹ/Nặng — các item nhị phân dẫn xuất phục vụ riêng cho tập luật kết hợp.

Biến đổi: rời rạc hóa nhiệt độ thành 4 khoảng, khung giờ thành 4 khung, gán nhóm thời tiết bằng từ khóa — để tạo item cho Apriori/FP-Growth ở Bài 3. Điền thiếu Precipitation, Wind_Speed, Humidity

theo trung vị State/tháng cho tập phân lớp (lưu ý: phép điền hiện fit trước khi chia train/test, cần sửa lại trong Bài 2 để tránh rò rỉ — đã nêu ở Mục 4.3).

5. Kiểm tra dữ liệu bàn giao

Dữ liệu	Kích thước	Ô thiếu	Cách sử dụng
Olist phân lớp	96.476×11	0	Loại ID khỏi đặc trưng; chia tập theo thời gian
Olist gom cụm	96.096×4	0	Loại customer_unique_id; biến đổi và scaling RFM
Airbnb luật kết hợp	30.218×182	0	Ma trận Boolean dùng cho Apriori/FP-Growth
Airbnb gom cụm	30.259×16	0	Đã điền thiếu; cần scaling
US phân lớp	80.000×23	0	Nên tạo lại từ bản còn thiếu và impute train-only
US luật kết hợp	80.000×32	0	Ma trận Boolean; lọc luật tầm thường

Dòng giống nhau sau khi chọn đặc trưng không tự động là bản ghi trùng. Hai khách hàng có thể có cùng RFM, hai listing có thể có cùng tiện nghi và hai tai nạn có thể có cùng nhóm điều kiện. Chỉ xóa khi mã sự kiện hoặc khóa nghiệp vụ xác nhận đó là cùng một bản ghi.

Mục tải và gộp Olist đã được kiểm tra lại trên dữ liệu gốc và cho kết quả 118.310×35 . Sáu CSV kỹ thuật được đọc lại và đều không có ô thiếu. Tuy nhiên workspace hiện chưa có dữ liệu gốc Airbnb và US Accidents, vì vậy chưa thể xác nhận toàn notebook Run All từ đầu cho hai bộ này.

Trước khi nộp, nhóm cần điền ngày tải thực tế của Airbnb và US Accidents, ghi ngày snapshot của Inside Airbnb, lưu checksum tệp gốc, sửa cách parse thời gian US Accidents và chạy lại notebook. Khi chạy xong phải kiểm tra lại số dòng, số cột, phân bố nhãn, tỷ lệ thiếu, số giỏ và tên cột của sáu tệp bàn giao.

Báo cáo chỉ mô tả các bước đã có bằng chứng trong notebook hoặc CSV. Các bước như StandardScaler, log-transform, SMOTE, huấn luyện mô hình và chọn siêu tham số thuộc Bài 2-4.

Phụ lục A. Từ điển dữ liệu Olist

Từ điển liệt kê từng thuộc tính theo metadata của notebook. Miền dưới đây là miền ngữ nghĩa/kiểu sử dụng dự kiến, không phải toàn bộ tập giá trị đã quan sát. Kiểu lưu CSV có thể là object hoặc float do thiếu dữ liệu; ngày phải parse trước khi tính. Không công bố các tên/URL cá nhân hay giá trị định danh mẫu trong phụ lục.

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
order_id	Mã định danh duy nhất của đơn hàng	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
order_item_id	Số thứ tự của sản phẩm trong một đơn hàng	Thứ tự	Hạng mục có thứ bậc hoặc thiếu
product_id	Mã định danh của sản phẩm	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
seller_id	Mã định danh của người bán	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
shipping_limit_date	Thời hạn dự kiến người bán giao sản phẩm cho đơn vị vận chuyển	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
price	Giá của sản phẩm trong đơn hàng	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
freight_value	Chi phí vận chuyển của sản phẩm	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
customer_id	Mã định danh của khách hàng gắn với đơn hàng	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
order_status	Trạng thái của đơn hàng	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
order_purchase_timestamp	Thời điểm khách hàng đặt hàng	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
order_approved_at	Thời điểm đơn hàng được hệ thống phê duyệt	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
order_delivered_carrier_date	Thời điểm đơn hàng được giao cho đơn vị vận chuyển	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
order_delivered_customer_date	Thời điểm đơn hàng được giao đến khách hàng	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
order_estimated_delivery_date	Thời điểm dự kiến giao đơn hàng cho khách	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
customer_unique_id	Mã định danh duy nhất của khách hàng	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
customer_zip_code_prefix	Mã vùng bưu chính của khách hàng	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
customer_city	Thành phố của khách hàng	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
customer_state	Bang của khách hàng	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
product_category_name	Danh mục của sản phẩm	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
product_name_lenght	Độ dài tên sản phẩm	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
product_description_lenght	Độ dài mô tả sản phẩm	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
product_photos_qty	Số lượng ảnh của sản phẩm	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
product_weight_g	Trọng lượng sản phẩm tính bằng gram	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
product_length_cm	Chiều dài sản phẩm tính bằng centimet	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
product_height_cm	Chiều cao sản phẩm tính bằng centimet	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
product_width_cm	Chiều rộng sản phẩm tính bằng centimet	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
seller_zip_code_prefix	Mã vùng bưu chính của người bán	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
seller_city	Thành phố của người bán	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
seller_state	Bang của người bán	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
product_category_name_english	Tên danh mục sản phẩm bằng tiếng Anh	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
payment_sequential	Thứ tự của phương thức thanh toán trong một đơn hàng	Thứ tự	Hạng mục có thứ bậc hoặc thiếu
payment_type	Phương thức thanh toán	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
payment_installments	Số lần thanh toán trả góp	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
payment_value	Giá trị thanh toán của giao dịch	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
			quan sát
review_score	Điểm đánh giá của khách hàng dành cho đơn hàng	Thứ tự	Số/thiếu; điểm nguyên 1-5

Phụ lục B. Từ điển dữ liệu Inside Airbnb

Từ điển liệt kê từng thuộc tính theo metadata của notebook. Miền dưới đây là miền ngữ nghĩa/kiểu sử dụng dự kiến, không phải toàn bộ tập giá trị đã quan sát. Kiểu lưu CSV có thể là object hoặc float do thiếu dữ liệu; ngày phải parse trước khi tính. Không công bố các tên/URL cá nhân hay giá trị định danh mẫu trong phụ lục.

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
id	Mã định danh của listing	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
listing_url	Địa chỉ trang listing trên Airbnb	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
scrape_id	Mã của lần thu thập dữ liệu	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
last_scraped	Ngày dữ liệu listing được thu thập gần nhất	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
source	Nguồn hoặc phương thức thu thập dữ liệu	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
name	Tên listing	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
description	Mô tả listing	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
neighborhood_overview	Mô tả tổng quan khu vực xung quanh listing	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
picture_url	Địa chỉ hình ảnh đại diện của listing	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
host_id	Mã định danh của host	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
host_url	Địa chỉ trang hồ sơ host	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
			đại lượng
host_profile_id	Mã hồ sơ của host	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
host_profile_url	Địa chỉ trang hồ sơ chi tiết của host	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
host_name	Tên host	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
host_since	Ngày host bắt đầu tham gia nền tảng	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
hosts_time_as_user_years	Số năm host đã sử dụng nền tảng với tư cách người dùng	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
hosts_time_as_user_months	Số tháng host đã sử dụng nền tảng với tư cách người dùng	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
hosts_time_as_host_years	Số năm host hoạt động với tư cách chủ nhà	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
hosts_time_as_host_months	Số tháng host hoạt động với tư cách chủ nhà	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
host_location	Địa điểm của host	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
host_about	Thông tin giới thiệu về host	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
host_response_time	Khoảng thời gian host thường phản hồi	Thứ tự	Hạng mục có thứ bậc hoặc thiếu
host_response_rate	Tỷ lệ phản hồi của host	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
host_acceptance_rate	Tỷ lệ chấp nhận yêu cầu đặt phòng của host	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
host_is_superhost	Cho biết host có đạt trạng thái Superhost hay không	Định danh	Hạng mục t/f hoặc thiếu
host_thumbnail_url	Địa chỉ ảnh thu nhỏ của host	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
host_picture_url	Địa chỉ ảnh hồ sơ của	Định danh	Chuỗi/mã/hạng mục hoặc

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
	host		thiếu; không diễn giải mã như đại lượng
host_neighbourhood	Khu vực của host	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
host_listings_count	Số listing của host	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
host_total_listings_count	Tổng số listing mà host quản lý	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
host_verifications	Các phương thức xác minh của host	Định danh	Danh sách lưu dạng chuỗi; tập mục
host_has_profile_pic	Cho biết host có ảnh hồ sơ hay không	Định danh	Hạng mục t/f hoặc thiếu
host_identity_verified	Cho biết danh tính host đã được xác minh hay chưa	Định danh	Hạng mục t/f hoặc thiếu
neighbourhood	Khu vực của listing	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
neighbourhood_cleansed	Khu vực đã được chuẩn hóa của listing	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
neighbourhood_group_cleansed	Nhóm khu vực lớn đã được chuẩn hóa	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
latitude	Vĩ độ của listing	Khoảng	Số; vĩ độ [-90,90]
longitude	Kinh độ của listing	Khoảng	Số; kinh độ [-180,180]
property_type	Loại hình bất động sản	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
room_type	Loại hình phòng	Định danh	Chuỗi; Entire home/apt, Private room, Shared room, Hotel room
accommodates	Số lượng khách tối đa có thể lưu trú	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
bathrooms	Số lượng phòng tắm	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
bathrooms_text	Mô tả dạng văn bản về số lượng phòng tắm	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
bedrooms	Số lượng phòng ngủ	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
beds	Số lượng giường	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
amenities	Danh sách các tiện nghi của listing	Định danh	Danh sách lưu dạng chuỗi; tập mục
price	Giá thuê listing mỗi đêm	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
price_quote_checkin_date	Ngày bắt đầu của báo giá	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
price_quote_checkout_date	Ngày kết thúc của báo giá	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
price_quote_total_price	Tổng giá trị báo giá	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
price_quote_price_per_night	Giá báo giá trung bình mỗi đêm	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
price_quote_raw	Thông tin báo giá ở dạng dữ liệu gốc	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
minimum_nights	Số đêm tối thiểu phải đặt	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
maximum_nights	Số đêm tối đa được phép đặt	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
minimum_minimum_nights	Giá trị nhỏ nhất của số đêm tối thiểu	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
maximum_minimum_nights	Giá trị lớn nhất của số đêm tối thiểu	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
minimum_maximum_nights	Giá trị nhỏ nhất của số đêm tối đa	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
maximum_maximum_nights	Giá trị lớn nhất của số đêm tối đa	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
minimum_nights_avg_ntm	Trung bình số đêm tối thiểu trong các tháng tiếp theo	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
maximum_nights_avg_ntm	Trung bình số đêm tối đa trong các tháng tiếp theo	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
calendar_updated	Thời điểm cập nhật lịch	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
has_availability	Cho biết listing có thông tin availability hay không	Định danh	Hạng mục t/f hoặc thiếu
availability_30	Số ngày có thể đặt trong 30 ngày	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
availability_60	Số ngày có thể đặt trong 60 ngày	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
availability_90	Số ngày có thể đặt trong 90 ngày	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
availability_365	Số ngày có thể đặt trong 365 ngày	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
calendar_last_scraped	Ngày lịch được thu thập gần nhất	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
number_of_reviews	Tổng số lượt đánh giá	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
number_of_reviews_ltm	Số lượt đánh giá trong 12 tháng gần nhất	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
number_of_reviews_l30d	Số lượt đánh giá trong 30 ngày gần nhất	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
availability_eoy	Số ngày còn khả dụng đến cuối năm	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
number_of_reviews_ly	Số lượt đánh giá trong năm trước	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
estimated_occupancy_l365d	Tỷ lệ lấp đầy ước tính trong 365 ngày	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
estimated_revenue_l365d	Doanh thu ước tính trong 365 ngày	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
first_review	Ngày có đánh giá đầu tiên	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
last_review	Ngày có đánh giá gần nhất	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
review_scores_rating	Điểm đánh giá tổng thể	Khoảng	Số/thiếu; điểm đánh giá (kiểm tra phiên bản thang điểm)
review_scores_accuracy	Điểm đánh giá độ chính xác của listing	Khoảng	Số/thiếu; điểm đánh giá (kiểm tra phiên bản thang điểm)
review_scores_cleanliness	Điểm đánh giá độ sạch sẽ	Khoảng	Số/thiếu; điểm đánh giá (kiểm tra phiên bản thang điểm)
review_scores_checkin	Điểm đánh giá quá trình check-in	Khoảng	Số/thiếu; điểm đánh giá (kiểm tra phiên bản thang điểm)
review_scores_communication	Điểm đánh giá khả năng giao tiếp của host	Khoảng	Số/thiếu; điểm đánh giá (kiểm tra phiên bản thang điểm)
review_scores_location	Điểm đánh giá vị trí	Khoảng	Số/thiếu; điểm đánh giá (kiểm tra phiên bản thang điểm)
review_scores_value	Điểm đánh giá tương quan giá trị và chi phí	Khoảng	Số/thiếu; điểm đánh giá (kiểm tra phiên bản thang điểm)
license	Thông tin giấy phép hoặc đăng ký của listing	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
instant_bookable	Cho biết listing có hỗ trợ đặt ngay hay không	Định danh	Hạng mục t/f hoặc thiếu
calculated_host_listings_count	Tổng số listing được tính cho host	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
calculated_host_listings_count_entire_homes	Số listing dạng toàn bộ căn hộ/nhà của host	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
calculated_host_listings_count_private_rooms	Số listing dạng phòng riêng của host	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
calculated_host_listings_count_shared_rooms	Số listing dạng phòng chung của host	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
reviews_per_month	Số lượt đánh giá trung bình mỗi tháng	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát

Phụ lục C. Từ điển dữ liệu US Accidents

Từ điển liệt kê từng thuộc tính theo metadata của notebook. Miền dưới đây là miền ngữ nghĩa/kiểu sử dụng dự kiến, không phải toàn bộ tập giá trị đã quan sát. Kiểu lưu CSV có thể là object hoặc float do thiếu dữ liệu; ngày phải parse trước khi tính. Không công bố các tên/URL cá nhân hay giá trị định danh mẫu trong phụ lục.

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
ID	Mã định danh duy nhất của vụ tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Source	Nguồn cung cấp dữ liệu tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Severity	Mức độ nghiêm trọng của vụ tai nạn	Thứ tự	Số nguyên; {1,2,3,4}
Start_Time	Thời điểm bắt đầu ảnh hưởng của vụ tai nạn	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
End_Time	Thời điểm kết thúc ảnh hưởng của vụ tai nạn	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
Start_Lat	Vĩ độ tại điểm bắt đầu	Khoảng	Số; vĩ độ [-90,90]
Start_Lng	Kinh độ tại điểm bắt đầu	Khoảng	Số; kinh độ [-180,180]
End_Lat	Vĩ độ tại điểm kết thúc	Khoảng	Số; vĩ độ [-90,90]
End_Lng	Kinh độ tại điểm kết thúc	Khoảng	Số; kinh độ [-180,180]
Distance(mi)	Chiều dài đoạn đường bị ảnh hưởng bởi vụ tai nạn	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
Description	Mô tả chi tiết về vụ tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Street	Tên đường xảy ra tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
City	Thành phố xảy ra tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
County	Quận/hạt xảy ra tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
State	Bang xảy ra tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Zipcode	Mã bưu chính tại vị trí xảy ra tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Country	Quốc gia xảy ra tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Timezone	Múi giờ tại vị trí xảy ra tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Airport_Code	Mã sân bay gần vị trí xảy ra tai nạn	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Weather_Timestamp	Thời điểm ghi nhận thông tin thời tiết	Khoảng	Ngày/giờ hoặc số khoảng; không có gốc 0 tuyệt đối
Temperature(F)	Nhiệt độ tại thời điểm xảy ra tai nạn	Khoảng	Số; °F, có thể âm
Wind_Chill(F)	Nhiệt độ cảm nhận do ảnh hưởng của gió	Khoảng	Số; °F, có thể âm
Humidity(%)	Độ ẩm không khí	Tỉ lệ	Số; [0,100] hoặc thiếu
Pressure(in)	Áp suất khí quyển	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
Visibility(mi)	Tầm nhìn tại thời điểm xảy ra tai nạn	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
Wind_Direction	Hướng gió	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Wind_Speed(mph)	Tốc độ gió	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
Precipitation(in)	Lượng mưa	Tỉ lệ	Số không âm hoặc thiếu; miền nghiệp vụ, không phải min/max quan sát
Weather_Condition	Điều kiện thời tiết	Định danh	Chuỗi/mã/hạng mục hoặc thiếu; không diễn giải mã như đại lượng
Amenity	Cho biết gần vị trí tai nạn có tiện ích giao thông hay không	Định danh	Boolean; True/False
Bump	Cho biết có gờ giảm tốc gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Crossing	Cho biết có giao cắt đường bộ gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Give_Way	Cho biết có biển báo nhường đường gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Junction	Cho biết vụ tai nạn xảy ra gần nút giao hay không	Định danh	Boolean; True/False
No_Exit	Cho biết có đường cụt gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Railway	Cho biết có đường sắt gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Roundabout	Cho biết có vòng xuyến gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Station	Cho biết có trạm giao thông gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Stop	Cho biết có biển báo hoặc điểm dừng gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Traffic_Calming	Cho biết có biện pháp giảm tốc giao thông hay không	Định danh	Boolean; True/False
Traffic_Signal	Cho biết có tín hiệu giao thông gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Turning_Loop	Cho biết có vòng quay đầu xe gần vị trí tai nạn hay không	Định danh	Boolean; True/False
Sunrise_Sunset	Trạng thái ngày hoặc đêm dựa trên thời điểm mặt trời mọc/lặn	Định danh	Chuỗi; Day/Night/thiếu
Civil_Twilight	Trạng thái ngày hoặc đêm theo thời điểm chạng vạng dân dụng	Định danh	Chuỗi; Day/Night/thiếu
Nautical_Twilight	Trạng thái ngày hoặc đêm theo thời điểm chạng vạng hàng hải	Định danh	Chuỗi; Day/Night/thiếu

Thuộc tính	Ý nghĩa	Thang đo	Kiểu và miền
Astronomical_Twilight	Trạng thái ngày hoặc đêm theo thời điểm chạng vạng thiên văn	Định danh	Chuỗi; Day/Night/thiếu