

BÁO CÁO BÀI 2: PHÂN LỚP

1. Mục tiêu và dữ liệu thực nghiệm

Bài thực hành so sánh các mô hình phân lớp trên hai bộ dữ liệu đã tiền xử lý ở Bài 1. US Accidents dự đoán Severity với bốn lớp 1-4; Olist dự đoán is_late, trong đó 0 là đúng hạn và 1 là giao trễ. Mục tiêu kỹ thuật là chọn cấu hình phù hợp và đánh giá khả năng nhận diện lớp thiểu số, thay vì chỉ tối đa hóa accuracy.

Bộ dữ liệu	Quy mô / đầu vào	Phân phối nhãn
US Accidents	80.000 dòng × 23 cột; 22 đặc trưng	1: 520 (0,65%); 2: 65.334 (81,67%); 3: 13.439 (16,80%); 4: 707 (0,88%)
Olist	96.476 dòng × 11 cột; 8 đặc trưng	0: 89.941 (93,23%); 1: 6.535 (6,77%)

Hai tệp classification không có giá trị thiếu. Thí nghiệm US Accidents sử dụng 80.000 dòng hiện có, không sử dụng bộ 2,3 triệu dòng hay lấy mẫu 200.000-300.000 dòng. Tỷ lệ nhãn được đối chiếu trực tiếp với CSV đầu vào.

US Accidents dùng các biến thời tiết, Distance(mi), Hour_of_Day, Is_Weekend, cờ hạ tầng và Infra_Feature_Count. Olist loại order_id và order_purchase_timestamp; giữ purchase_month, purchase_dayofweek, purchase_hour, order_item_count, unique_product_count, unique_seller_count, total_order_price và total_freight_value.

2. Thuật toán và xử lý mất cân bằng

Decision Tree (DT) chia dữ liệu theo ngưỡng để tăng độ thuần nhãn của các nút. Mô hình biểu diễn quan hệ phi tuyến và tương tác giữa đặc trưng, không cần scale; độ sâu lớn có thể gây quá khớp. **Logistic Regression (LR)** mô hình hóa log-odds tuyến tính theo đầu vào, có thể hạn chế khi quan hệ phi tuyến mạnh. StandardScaler được đặt trong pipeline để chỉ fit trên dữ liệu huấn luyện.

kNN dự đoán bằng nhãn của các điểm lân cận, dựa trên giả định điểm gần nhau có xu hướng cùng lớp. Thuật toán nhạy với thang đo, nhiễu và tỷ lệ lớp nên được chuẩn hóa trong pipeline Olist. **Dummy** luôn dự đoán lớp đa số, giúp xác định mức accuracy đạt được mà không học quan hệ giữa đặc trưng và nhãn.

US Accidents giữ đủ bốn lớp; DT và LR cố định class_weight=balanced để tăng đóng góp của lớp hiếm. Olist thử cả None và balanced cho DT/LR. Trọng số lớp có thể tăng khả năng phát hiện lớp thiểu số nhưng cũng tăng dự đoán sai vào lớp này, nên phải xem precision và recall đồng thời.

3. Thiết kế thí nghiệm và chọn tham số

US Accidents: tách test 20% (16.000 mẫu); 64.000 mẫu còn lại tiếp tục chia thành train 51.200 và validation 12.800. Cả hai lần chia dùng stratify và random_state=42. Chọn max_depth theo F1-macro trên validation; sau đó fit lại từng mô hình trên toàn bộ 64.000 mẫu train + validation và đánh giá test. Notebook không dùng GridSearchCV hay cross-validation cho bộ này.

Olist: chia train/test 80/20 (77.180/19.296 mẫu), stratify theo nhãn, seed=42. GridSearchCV dùng StratifiedKFold 5 phần, shuffle=True, seed=42 trên train, tối ưu F1 lớp trẻ. kNN dùng mẫu train stratified 40.000 dòng cho cả tuning và fit cuối; DT/LR dùng toàn bộ train. Vì vậy so sánh kNN còn chịu ảnh hưởng của quy mô huấn luyện.

Bộ / mô hình	Tham số khảo sát hoặc cố định	Cách chọn
US / DT	max_depth: {4, 6, 8, 10, 12}; min_samples_leaf=20; class_weight=balanced	F1-macro validation
US / LR	C=1 (mặc định); solver=lbfgs; class_weight=balanced; max_iter=2000	Cấu hình đối chứng cố định; không tuning C
Olist / DT	max_depth: {3, 5, 7, 10, None}; min_samples_leaf: {50, 100, 300}; class_weight: {None, balanced}	CV 5-fold, F1 lớp trẻ
Olist / LR	C: {0.1, 1, 10}; class_weight: {None, balanced}; max_iter=2000	CV 5-fold, F1 lớp trẻ
Olist / kNN	k: {3, 5, 7, 9, 11}; weights: {uniform, distance}	CV 5-fold, F1 lớp trẻ

Giới hạn độ sâu và kích thước lá giúp kiểm soát độ phức tạp của cây; lá tối thiểu 20 mẫu không bảo đảm mỗi lá có đủ lớp hiếm. LR của US Accidents là mô hình đối chứng có điều chuẩn L2, chưa khảo sát C nên kết luận chỉ áp dụng cho cấu hình hiện có. Olist khảo sát ba mức C và các giá trị k nhỏ để so sánh điều chuẩn và cách bỏ phiếu.

Độ sâu DT (US)	4	6	8	10	12
F1-macro validation	0,1591	0,2016	0,2623	0,2663	0,2760

Chọn depth=12 trong tập giá trị đã thử. LR đạt F1-macro validation 0,2069; Dummy đạt 0,2248. F1-macro tính trung bình F1 của bốn lớp với trọng số bằng nhau. Balanced accuracy là trung bình recall từng lớp. Olist dùng F1 lớp trẻ và bổ sung ROC-AUC để đánh giá khả năng xếp hạng xác suất qua nhiều ngưỡng.

4. Kết quả US Accidents trên tập test

Mô hình	Accuracy	F1-macro	Balanced accuracy
Dummy	0.8167	0.2248	0.2500
DT	0.4843	0.2881	0.5297
LR	0.3222	0.2127	0.4629

DT dùng depth=12, min_samples_leaf=20, class_weight=balanced; LR dùng C=1, class_weight=balanced. Các số liệu dưới đây lấy từ output notebook phan-lop.ipynb.

Lớp / support	DT P	DT R	DT F1	LR P	LR R	LR F1
1 / 104	0.0283	0.5385	0.0537	0.0169	0.6442	0.0330
2 / 13067	0.9383	0.4537	0.6116	0.9344	0.2680	0.4165
3 / 2688	0.3341	0.6302	0.4367	0.2652	0.5707	0.3621
4 / 141	0.0266	0.4965	0.0505	0.0207	0.3688	0.0393

P = precision, R = recall. Ma trận nhầm lẫn: hàng là nhãn thực, cột là nhãn dự đoán theo thứ tự 1, 2, 3, 4.

Thực	DT → 1	DT → 2	DT → 3	DT → 4	LR → 1	LR → 2	LR → 3	LR → 4
1	56	13	31	4	67	6	28	3
2	1491	5928	3330	2318	3094	3502	4193	2278
3	428	326	1694	240	783	197	1534	174
4	5	51	15	70	16	43	30	52

Dummy đạt accuracy 81,67% nhưng F1-macro chỉ 0,2248; không phát hiện lớp 1, 3, 4. **DT** đạt F1-macro 0,2881, cao nhất trong ba mô hình; nhận đúng 56/104 mẫu lớp 1 và 70/141 mẫu lớp 4. Recall tương ứng 53,85% và 49,65%, nhưng precision chỉ 2,83% và 2,66%: phần lớn dự đoán vào hai lớp hiếm vẫn sai.

LR balanced nhận đúng 67/104 mẫu lớp 1 (64,42%) và 52/141 mẫu lớp 4 (36,88%). Mô hình không chỉ đoán lớp 2, nhưng recall lớp 2 giảm xuống 26,80%, precision lớp 1 và 4 chỉ 1,69% và 2,07%. F1-macro 0,2127 thấp hơn Dummy dù balanced accuracy cao hơn (0,4629 so với 0,2500), thể hiện đánh đổi giữa recall và precision.

DT là lựa chọn phù hợp nhất trong phạm vi khảo sát, không đồng nghĩa mô hình đã tốt: tỷ lệ bỏ sót lớp 1 và 4 còn 46,15% và 50,35%. Chỉ 104 và 141 mẫu test thuộc hai lớp này nên các chỉ số có thể dao động giữa các lần chia dữ liệu. Độ sâu tốt nhất nằm ở biên trên của dải thử; chưa có bằng chứng đây là tối ưu ngoài dải đó.

5. Kết quả Olist trên tập test

DT tối ưu có `class_weight=balanced`, `max_depth=3`, `min_samples_leaf=50` (CV F1=0,2228); LR có `C=10`, `class_weight=balanced` (0,1502); kNN có `k=3`, `weights=distance` (0,0753). DT dẫn đầu theo tiêu chí CV đã chọn. Kết quả lấy từ output `phan-lop-olist.ipynb`.

Mô hình	Accuracy	Lớp 0: P / R / F1	Lớp 1: P / R / F1	ROC-AUC
Dummy	0.9323	0.9323 / 1.0000 / 0.9649	0.0000 / 0.0000 / 0.0000	0.5000
DT	0.7483	0.9585 / 0.7631 / 0.8497	0.1433 / 0.5455 / 0.2270	0.6828
LR	0.5627	0.9484 / 0.5615 / 0.7054	0.0876 / 0.5792 / 0.1521	0.5749
kNN	0.9087	0.9338 / 0.9709 / 0.9520	0.1151 / 0.0520 / 0.0717	0.5409

Support lớp 0: 17.989; lớp 1: 1.307. Chỉ số từng lớp được tính từ ma trận nhầm lẫn; ROC-AUC lấy từ output đã lưu.

Hàng thực / cột dự đoán	Dummy	DT	LR	kNN
Thực 0 → [0, 1]	[17989, 0]	[13727, 4262]	[10101, 7888]	[17466, 523]
Thực 1 → [0, 1]	[1307, 0]	[594, 713]	[550, 757]	[1239, 68]

Dummy có accuracy 93,23% nhưng không phát hiện đơn trễ nào. DT phát hiện 713/1.307 đơn trễ, recall 54,55%, F1=0,2270, ROC-AUC=0,6828; đổi lại có 4.262 cảnh báo sai, precision 14,33%. LR có recall cao hơn (57,92%) nhưng 7.888 cảnh báo sai nên F1 thấp hơn (0,1521). kNN bỏ sót 1.239/1.307 đơn trễ; accuracy 90,87% không phản ánh tốt khả năng nhận diện lớp thiểu số.

6. Giới hạn và kết luận

US Accidents đã được điền thiếu bằng median ở Bài 1 trước khi chia tập, nên có nguy cơ rò rỉ thông tin phân phối test vào tiền xử lý. Distance(mi) là chiều dài đoạn đường bị ảnh hưởng, có thể chưa có tại thời điểm cảnh báo ban đầu; kết quả hiện tại phản ánh phân lớp bản ghi đã quan sát. Để kiểm chứng chặt chẽ hơn, cần fit imputer chỉ trên train và đánh giá tính sẵn có của đặc trưng.

DT được chọn cho cả hai bộ trong phạm vi thí nghiệm: US Accidents theo F1-macro validation, Olist theo CV F1 lớp trễ; test xác nhận thứ hạng này. Không so sánh trực tiếp hai giá trị F1 vì chúng có cách tổng hợp khác nhau. Mô hình còn nhiều dự đoán sai ở lớp thiểu số. Hướng tiếp theo là khảo sát thêm tham số trên train/validation, bổ sung PR-AUC cho Olist và dùng tập kiểm tra độc lập cho các cải tiến.