

BÁO CÁO BÀI 2: PHÂN LỚP

1. Mục tiêu và dữ liệu thực nghiệm

Bài thực hành xây dựng và so sánh các mô hình phân lớp trên hai bộ dữ liệu đã tiền xử lý ở Bài 1. US Accidents dự đoán Severity với bốn lớp 1-4; Olist dự đoán is_late, trong đó 0 là đúng hạn và 1 là giao trễ. Trọng tâm là chọn siêu tham số có phương pháp và đánh giá khả năng nhận diện lớp thiểu số, thay vì chỉ tối đa hóa accuracy.

Bộ dữ liệu	Quy mô / đặc trưng	Phân phối nhãn thực tế
US Accidents	80.000 dòng × 23 cột; 22 đầu vào	1: 520 (0,65%); 2: 65.334 (81,67%); 3: 13.439 (16,80%); 4: 707 (0,88%)
Olist	96.476 dòng × 11 cột; 8 đầu vào	0: 89.941 (93,23%); 1: 6.535 (6,77%)

Hai tệp classification không có giá trị thiếu. Quy mô US Accidents sử dụng thực tế là 80.000 dòng; các gợi ý lấy mẫu 200.000-300.000 dòng trong hướng dẫn không áp dụng cho tệp này. Tỷ lệ nhãn trong báo cáo lấy trực tiếp từ dữ liệu hiện có.

US Accidents dùng nhóm biến thời tiết, Distance(mi), giờ trong ngày, cò cuối tuần, các cò hạ tầng và Infra_Feature_Count. Olist loại order_id và order_purchase_timestamp; giữ purchase_month, purchase_dayofweek, purchase_hour, order_item_count, unique_product_count, unique_seller_count, total_order_price và total_freight_value.

2. Thiết kế đánh giá và giả định thuật toán

Mỗi bộ được chia train/test 80/20 với stratify theo nhãn và random_state=42: US Accidents có 64.000/16.000 mẫu, Olist có 77.180/19.296 mẫu. GridSearchCV dùng StratifiedKFold 5 phần, shuffle=True, seed=42 trên train; cấu hình tốt nhất được fit lại trước khi đánh giá test. Không điều chỉnh siêu tham số theo kết quả test.

Decision Tree (DT) chia không gian đầu vào theo ngưỡng nhằm tăng độ thuần nhãn; phù hợp quan hệ phi tuyến, không cần chuẩn hóa nhưng dễ quá khớp khi cây sâu. **Logistic Regression (LR)** giả định log-odds có quan hệ tuyến tính với đặc trưng; chuẩn hóa giúp tối ưu ổn định. **kNN** giả định các điểm gần nhau có nhãn tương tự, nhạy với thang đo và mất cân bằng. Dummy luôn đoán lớp đa số được dùng làm mốc tham chiếu.

DT và LR thử cả class_weight=None và balanced; trọng số balanced tăng đóng góp của lớp hiếm vào quá trình học. US Accidents giữ đủ bốn lớp để quan sát mức 1 và 4. LR dùng StandardScaler trong pipeline; Olist kNN cũng chuẩn hóa, còn bước impute/encode trong pipeline Olist chỉ fit trên train.

3. Chọn siêu tham số và tiêu chí so sánh

Bộ / mô hình	Không gian tìm kiếm	Tiêu chí CV
US / DT	max_depth: 3, 5, 7, 10, 15; min_samples_leaf: 20, 50; class_weight: None, balanced	F1-macro
US / LR	C: 0.1, 1, 10; class_weight: None, balanced; max_iter=2000	F1-macro
Olist / DT	max_depth: 3, 5, 7, 10, None; min_samples_leaf: 50, 100, 300; class_weight: None, balanced	F1 lớp trẻ
Olist / LR	C: 0.1, 1, 10; class_weight: None, balanced; max_iter=2000	F1 lớp trẻ
Olist / KNN	k: 3, 5, 7, 9, 11; weights: uniform, distance	F1 lớp trẻ

Độ sâu và kích thước lá giới hạn độ phức tạp của cây; C khảo sát ba mức điều chuẩn của LR. KNN thử số láng giềng nhỏ và hai cách bỏ phiếu. US Accidents dùng toàn bộ 64.000 mẫu train. Olist kNN dùng mẫu train stratified 40.000 dòng cho cả tuning và fit cuối, trong khi DT/LR dùng toàn bộ train; vì vậy chênh lệch kết quả không chỉ do thuật toán.

F1-macro là trung bình F1 của bốn lớp với trọng số bằng nhau, giúp lớp 2 không lấn át lớp 1 và 4. Olist tối ưu F1 lớp trẻ để cân bằng precision và recall. Báo cáo bổ sung accuracy, precision/recall/F1 từng lớp và ma trận nhầm lẫn; ROC-AUC của Olist đo khả năng xếp hạng xác suất qua nhiều ngưỡng.

4. Kết quả US Accidents

Mô hình	Cấu hình tốt nhất	CV F1-macro	Test accuracy	Test F1-macro
Dummy	Luôn dự đoán lớp 2	-	0.8167	0.2248
Decision Tree	depth=15; leaf=20; weight=balanced	0.3045	0.5436	0.3056
Logistic Regression	C=1; weight=None	0.2274	0.8167	0.2259

Mô hình được chọn theo CV F1-macro là **Decision Tree**. Dummy đạt accuracy 81.67% nhưng F1-macro chỉ 0.2248; precision, recall và F1 của các lớp 1, 3, 4 đều bằng 0. Đây là bằng chứng cho thấy accuracy cao có thể chỉ phản ánh ưu thế của lớp đa số.

Kết quả US Accidents được chạy bổ sung bằng `thuc-nghiem-us-accidents.py`; số liệu chi tiết lưu tại `ket-qua-us-accidents.json`. Phiên bản `scikit-learn`: 1.9.0. Kết quả Olist ở phần sau được trích từ output đã lưu trong `phan-lop.ipynb`, không phải lượt huấn luyện mới trong lần lập báo cáo này.

4.1. Đánh giá theo từng lớp US Accidents

Lớp / support	DT precision	DT recall	DT F1	LR precision	LR recall	LR F1
1 / 104	0.0327	0.4231	0.0607	0.0000	0.0000	0.0000
2 / 13,067	0.9235	0.5277	0.6716	0.8169	0.9995	0.8991
3 / 2,688	0.3357	0.6328	0.4387	0.5000	0.0022	0.0044
4 / 141	0.0273	0.4113	0.0513	0.0000	0.0000	0.0000

4.2. Ma trận nhầm lẫn 4 × 4

Hàng là nhãn thực, cột là nhãn dự đoán; thứ tự lớp 1, 2, 3, 4.

Nhãn thực	DT → 1	DT → 2	DT → 3	DT → 4	LR → 1	LR → 2	LR → 3	LR → 4
1	44	21	36	3	0	104	0	0
2	1022	6895	3312	1838	0	13061	6	0
3	274	490	1701	223	0	2682	6	0
4	5	60	18	58	0	141	0	0

Decision Tree: nhận diện đúng 44/104 mẫu lớp 1 (recall 42.31%) và 58/141 mẫu lớp 4 (recall 41.13%). Tỷ lệ bỏ sót tương ứng là 57.69% và 58.87%; precision hai lớp là 0.0327 và 0.0273. Do đó cần xem đồng thời khả năng phát hiện lớp hiếm và số dự đoán nhầm vào các lớp này.

Logistic Regression: nhận diện đúng 0/104 mẫu lớp 1 (recall 0.00%) và 0/141 mẫu lớp 4 (recall 0.00%). Tỷ lệ bỏ sót tương ứng là 100.00% và 100.00%; precision hai lớp là 0.0000 và 0.0000. Do đó cần xem đồng thời khả năng phát hiện lớp hiếm và số dự đoán nhầm vào các lớp này.

LR dự đoán lớp 2 cho 15.988/16.000 mẫu (99,925%), gần như lặp lại baseline và bỏ sót toàn bộ lớp 1, 4. DT phát hiện được hai lớp hiếm nhưng precision đều dưới 3,3%, tức phần lớn dự đoán vào hai lớp này là sai. Chỉ có 104 và 141 mẫu test ở lớp 1 và 4 nên các chỉ số có thể dao động giữa các lần chia dữ liệu.

4.3. Giới hạn diễn giải

Bài 1 ghi nhận bước điền thiếu bằng median được thực hiện trước khi chia train/test. Vì vậy kết quả US Accidents có nguy cơ lạc quan do thông tin phân phối test đã tham gia tiền xử lý. Ngoài ra, Distance(mi) là chiều dài đoạn đường chịu ảnh hưởng của tai nạn, có thể chưa sẵn có tại thời điểm cảnh báo ban đầu. Kết quả hiện tại mô tả phân lớp bản ghi đã quan sát; chưa chứng minh năng lực dự báo trước tai nạn.

5. Kết quả Olist

DT tối ưu có `class_weight=balanced`, `max_depth=3`, `min_samples_leaf=50` (CV F1=0,2228); LR có `C=10`, `class_weight=balanced` (0,1502); kNN có `k=3`, `weights=distance` (0,0753). DT dẫn đầu theo tiêu chí CV đã chọn.

Mô hình	Accuracy	Lớp 0: P / R / F1	Lớp 1: P / R / F1	ROC-AUC
Dummy	0.9323	0.9323 / 1.0000 / 0.9649	0.0000 / 0.0000 / 0.0000	0.5000
DT	0.7483	0.9585 / 0.7631 / 0.8497	0.1433 / 0.5455 / 0.2270	0.6828
LR	0.5627	0.9484 / 0.5615 / 0.7054	0.0876 / 0.5792 / 0.1521	0.5749
kNN	0.9087	0.9338 / 0.9709 / 0.9520	0.1151 / 0.0520 / 0.0717	0.5409

P = precision, R = recall. Support lớp 0: 17.989; lớp 1: 1.307. Các chỉ số từng lớp được tính từ ma trận nhầm lẫn lưu trong notebook.

Ma trận: hàng thực / cột dự đoán	Dummy	DT	LR	kNN
Thực 0 → [0, 1]	[17989, 0]	[13727, 4262]	[10101, 7888]	[17466, 523]
Thực 1 → [0, 1]	[1307, 0]	[594, 713]	[550, 757]	[1239, 68]

Dummy đạt accuracy 93,23% nhưng không phát hiện đơn trể nào. DT phát hiện 713/1.307 đơn trể, recall 54,55%, F1=0,2270 và ROC-AUC=0,6828; đổi lại có 4.262 cảnh báo sai, precision chỉ 14,33%. LR có recall cao hơn (57,92%) nhưng tạo 7.888 cảnh báo sai nên F1 thấp hơn (0,1521). kNN bỏ sót 1.239/1.307 đơn trể; accuracy 90,87% không phản ánh tốt khả năng phát hiện lớp này.

6. Kết luận và hướng hoàn thiện

Trên US Accidents, Decision Tree được chọn theo F1-macro của cross-validation; đánh giá phải kèm chỉ số lớp 1 và 4 để tránh kết luận từ lớp đa số. Trên Olist, DT phù hợp nhất trong phạm vi các mô hình khảo sát theo F1 lớp trể, nhưng chất lượng còn hạn chế và số cảnh báo sai cao. Không so sánh trực tiếp F1-macro của US Accidents với F1 lớp trể của Olist vì đây là hai cách tổng hợp khác nhau.

Để kiểm chứng chặt chẽ hơn, cần fit bước điền thiếu US Accidents chỉ trên train, đánh giá theo thời gian/nhóm khi có dữ liệu tương ứng và kiểm tra tính sẵn có của đặc trưng tại thời điểm dự đoán. Với Olist, có thể chọn ngưỡng trên validation, bổ sung PR-AUC và cho kNN học cùng quy mô train. Mọi cải tiến cần được đánh giá trên tập kiểm tra độc lập, không dùng test hiện tại để tiếp tục tuning.

Nguồn nội bộ: HUONG_DAN_LAM_BAI.md; hai tệp classification trong data/processed; notebook Bài 1 khao-sat.ipynb; notebook Bài 2 phan-lop.ipynb (Olist); thuc-nghiem-us-accidents.py và ket-qua-us-accidents.json (US Accidents).