

Báo cáo kỹ thuật — Bài báo cáo 3: Luật kết hợp

1. Chuẩn bị dữ liệu giao dịch

1.1 US Accidents — 80.000 giao dịch × 32 item

Đơn vị giao dịch: mỗi dòng là một vụ tai nạn giao thông, mỗi cột là một item nhị phân (True/False). Dữ liệu đầu vào gồm 80.000 giao dịch × 32 item, kế thừa từ bước chuẩn bị dữ liệu trước đó (us_accidents_association_transactions.csv). 32 item được ghép từ 2 nhóm:


- **(a) 9 cờ hạ tầng có sẵn dạng nhị phân:** Crossing, Junction, Traffic_Signal, Railway, Station, Stop, Amenity, Give_Way, No_Exit.
- **(b) 23 item được rời rạc hóa / one-hot** từ thuộc tính số và hạng mục liên tục.

Lý do bổ sung nhóm rời rạc hóa: nếu chỉ dùng cờ hạ tầng, hơn 92% giao dịch chỉ có 0–1 item, không đủ để sinh luật hai vế có ý nghĩa. Sau khi bổ sung, mỗi giao dịch có tối thiểu 5 item (trung bình 6,37), 100% giao dịch có ≥ 2 item.

Thuộc tính gốc	Cách rời rạc hóa	Item kết quả
Hour_of_Day (0–23)	4 khung giờ + Unknown nếu thiếu: Sáng (5–10h), Trưa/Chiều (11–16h), Tối (17–20h), Đêm (21–4h)	GioTrongNgay_*
Is_Weekend (bool)	Giữ nguyên, đổi nhãn	LoaiNgay_NgayThuong / CuoiTuan
Temperature_Bin	Nhóm nhiệt độ đã rời rạc hóa từ trước	NhietDo_* (gồm cả Unknown)
Weather_Condition (text)	Gộp nhóm theo từ khóa thời tiết	ThoiTiet_* (gồm cả Unknown)
Sunrise_Sunset	Giữ nguyên, đổi nhãn	AnhSang_Day / Night
Severity (1–4)	Gộp nhị phân: 1,2 → Nhẹ; 3,4 → Nặng	MucDo_Nhe / MucDo_Nang

1.2 Airbnb — 30.218 giao dịch × 182 item

Đơn vị giao dịch = 1 listing; item = 1 tiện nghi nhị phân trong amenities, TB 27,8 item/giao dịch, đã nhị phân hóa sẵn từ Bài 1, không cần rời rạc hóa thêm. Wifi (93,57%), Smoke alarm (92,93%), Kitchen (86,30%) gần như phổ biến tuyệt đối → loại 3 item này (ngưỡng >0,85) trước khi khai phá, còn 179 item.




Hình 1. Airbnb: 3 tiện nghi phổ biến bị loại trước khi khai phá

2. Thuật toán và ngưỡng


Áp dụng 2 thuật toán cùng nguyên lý cho cả 2 bộ dữ liệu. Apriori: dựa trên tính chất downward closure (mọi tập con của tập phổ biến cũng phổ biến) → loại sớm ứng viên chứa tập con không phổ biến; duyệt theo từng mức, để bù đắp ứng viên khi min_support thấp. FP-Growth: không sinh ứng viên tường minh, nén dữ liệu vào cây FP-tree dùng chung tiền tố, khai thác đệ quy trên cây điều kiện con. Cả hai là thuật toán chính xác (không xấp xỉ) — cho cùng một kết quả tập phổ biến, chỉ khác cách tìm và tốc độ.

2.1 US Accidents — chọn ngưỡng

Thuật toán	min_support	Số tập phổ biến	Thời gian (giây)
Apriori	0,3%	3659	3,460
Apriori	1%	1504	0,645
Apriori	3%	572	0,150
FP-Growth	0,3%	3659	0,404
FP-Growth	1%	1504	0,353
FP-Growth	3%	572	0,330



Hình 2. US Accidents: Số tập phổ biến theo ngưỡng



Hình 3. US Accidents: Thời gian Apriori vs FP-Growth theo ngưỡng


Thuật toán	min_support	Số tập phổ biến	Thời gian (giây)
	<i>min_support</i>		<i>ngưỡng</i>

Tốc độ không nhất quán ở cả 3 ngưỡng: FP-Growth nhanh hơn rõ ở ngưỡng thấp (0,3%: 0,404s so với 3,460s), nhưng Apriori nhanh hơn ở ngưỡng cao (3%: 0,150s so với 0,330s) → không thuật toán nào luôn thắng. Ngưỡng chọn: min_support = 1%, min_confidence = 20% — confidence thấp có chủ đích vì MucDo_Nang chỉ chiếm 17,7% nền.


2.2 Airbnb — chọn ngưỡng

Vì dữ liệu dày đặc hơn nhiều (182 item, TB 27,8/giao dịch so với 32 item, TB 6,37 ở US Accidents), nhóm thử ngưỡng cao hơn hẳn:

min_support	0,20	0,15	0,10	0,08
Số tập phổ biến	24.941	126.142	1.219.391	4.195.080
Th.gian FP-Growth (s)	3,33	8,69	40,75	111,66



Hình 4. Airbnb: Số tập phổ biến theo ngưỡng min_support



Hình 5. Airbnb: Thời gian chạy FP-Growth theo ngưỡng min_support

Ngưỡng chọn: min_support = 0,20, min_confidence = 0,60. Ở 0,15 dù itemsets phong phú hơn, bước sinh luật bùng nổ tới 5.878.572 luật — không khả thi để lọc. Ngưỡng 0,20 là điểm cân bằng khả thi giữa tính toán và độ đa dạng luật.

3. Lọc luật

3.1 US Accidents

Sinh luật ban đầu: 9.577. Lọc lift > 1,2 (loại luật tầm thường do item nền tần suất cao) còn 4.244. Lọc luật dư thừa (antecedent dài hơn không tăng confidence so với luật cha) còn 2.323. Lọc luật chứa item_Unknown (lift cao nhất 38–39 chỉ do 2 thuộc tính cùng thiếu dữ liệu) còn 2.178 luật nghiệp vụ.

3.2 Airbnb

Sinh luật: 711.995. Lọc lift >1,2 → còn 694.073 (giảm ít vì phần lớn cặp item vẫn vượt ngưỡng lift). Do quy mô lớn, lấy top 200 theo lift trước khi loại luật dư thừa — toàn bộ 200 luật hàng đầu đều giữ nguyên, không phát sinh luật dư thừa trong tập này.

4. Luật nổi bật

4.1 US Accidents — hướng tới MucDo_Nang

Điều kiện (A)	Support	Confidence	Lift
Junction, NhietDo_Vua	0,0111	0,2667	1,509
NhietDo_Vua, AnhSang_Day, LoaiNgay_CuoiTuan	0,0122	0,2588	1,464
LoaiNgay_CuoiTuan, ThoiTiet_Nhieu_May	0,0129	0,2545	1,439
GioTrongNgay_Sang, NhietDo_Vua, ThoiTiet_Nhieu_May	0,0133	0,2537	1,435
NhietDo_Vua, LoaiNgay_CuoiTuan	0,0172	0,2454	1,388
AnhSang_Day, Junction	0,0149	0,2432	1,375
Junction	0,0219	0,2392	1,353

Luật mạnh nhất: {Junction, NhietDo_Vua} → MucDo_Nang, lift 1,51. Trong 29 luật hướng tới MucDo_Nang, phần lớn có lift 1,2–1,4 — tương quan tồn tại nhưng không mạnh. Đối chứng MucDo_Nhe: 0 luật đạt lift >1,2 — vì MucDo_Nhe chiếm 82,3% nền nên cần confidence >98,8% mới đạt lift 1,2 (bất khả thi), trong khi MucDo_Nang chỉ cần >21,2%.

4.2 Airbnb — cụm nhà bếp đầy đủ

Top 10 luật đều có lift 2,70–2,73, xoay quanh cụm Refrigerator, Stove, Oven, Dishes and silverware, Cooking basics, Hot water:

Antecedent → Consequent	Supp.	Conf.	Lift
{Dishes & Silverware, Essentials, Oven} → {Cooking basics, Hot water, Refrigerator, Stove}	0,2017	0,7230	2,734
{Refrigerator, Stove} → {Dishes & Silverware, Heating, Oven}	0,2038	0,6661	2,712
{Cooking basics, Wine glasses} → {Dishes & Silverware, Freezer, Hot water}	0,2014	0,6708	2,707

Đọc luật đầu: 20,17% listing có đồng thời cả 7 tiện nghi; 72,3% trong số có 3 tiện nghi về trái cũng có đủ 4 tiện nghi về phải — khả năng đồng xuất hiện cao gấp 2,73 lần ngẫu nhiên. Luật 3:

Wine glasses (không thuộc nhóm bếp cơ bản) vẫn gắn chặt với cụm bếp đầy đủ — gợi ý phân khúc listing đầu tư đồng bộ tiện nghi nấu ăn lẫn cao cấp.

5. Tổng kết kỹ thuật và so sánh 2 bộ dữ liệu

Thuật toán: ở cả 2 bộ, Apriori và FP-Growth cho cùng kết quả tập phổ biến; tốc độ phụ thuộc ngưỡng và mật độ dữ liệu, không thuật toán nào luôn nhanh hơn — US Accidents cho thấy điều này rõ ở 3 ngưỡng khác nhau, Airbnb củng cố thêm với 2 ngưỡng khác.

Ngưỡng: mật độ item quyết định thang ngưỡng phải dùng — US Accidents (32 item, TB 6,37/giao dịch) dùng min_support 0,3–3%, trong khi Airbnb (182 item, TB 27,8/giao dịch) phải dùng min_support 8–20%, cao hơn cả trăm lần, để việc sinh/lọc luật khả thi về mặt tính toán.

Phát hiện chính: US Accidents cho 29 luật liên quan MucDo_Nang (mạnh nhất Junction + NhietDo_Vua, lift 1,51) nhưng 0 luật liên quan MucDo_Nhe cùng ngưỡng — do chênh lệch support nền giữa 2 lớp (17,7% và 82,3%), không phải thiếu luật thật. Airbnb cho các luật rất mạnh (lift 2,70–2,73) xoay quanh cụm tiện nghi nhà bếp đầy đủ, phản ánh một phân khúc listing đầu tư đồng bộ.

6. Hạn chế và ghi chú

Luật kết hợp chỉ phản ánh đồng xuất hiện, không phải quan hệ nhân quả — ví dụ {Junction, NhietDo_Vua} → MucDo_Nang không có nghĩa là giao lộ và nhiệt độ vừa gây ra tai nạn nặng, chỉ cho thấy chúng thường xuất hiện cùng nhau hơn mức ngẫu nhiên.

Nhóm luật lift cao nhất ở US Accidents (38–39) xoay quanh các item _Unknown, là hệ quả của thiếu dữ liệu ở một số vụ tai nạn (61 giao dịch thiếu Thời tiết, 51 giao dịch thiếu Ánh sáng), không phải quan hệ nghiệp vụ thật — nhóm đã tách riêng để không lẫn vào tập luật dùng diễn giải.

Với Airbnb, do quy mô luật sinh ra rất lớn (711.995), nhóm chỉ xét kỹ top 200 theo lift thay vì toàn bộ tập luật — các luật lift thấp hơn nhưng vẫn có ý nghĩa nghiệp vụ có thể chưa được khảo sát hết trong phạm vi bài tập này.

Diễn giải ý nghĩa nghiệp vụ sâu hơn (ví dụ đề xuất cải thiện an toàn giao thông theo điều kiện, hay gợi ý tiện nghi cho chủ nhà Airbnb) được để dành cho đề án, theo đúng quy ước của đề bài.